

데이터 분석 프로젝트

8/20 ~ 8/25

방선기

1

프로젝트 일정

프로젝트 일정

8/20 (목) : 데이터셋 선정 / 문제 후보 발굴 / 문제정의 확정 / 데이터 전처리

8/21 (금) : 데이터 전처리 / 데이터 분석 (EDA / 시각화 / 인사이트 도출)

8/24 (월) : 데이터 분석 & 발표자료 준비

8/25 (화) : 발표자료 준비 & 팀별 발표

AIPM에게 데이터 분석 역량이란?

- **데이터를 직접 추출(SQL)하고** 해석하여, 제품의 문제를 정의하고 우선순위를 판단하는 근거를 마련하는 역할.
- 단순한 현황 파악을 넘어, 가설을 검증하고 제품의 성장 방향(Roadmap)을 제시할 수 있는 사람.
- 지표(Metric)를 바탕으로 팀원들을 설득하고 실행 가능한 액션플랜(Action Item)을 도출하는 역량.
- 서비스의 사용률·만족도·이탈 지점을 데이터로 짚어내고, 개선 방향까지 근거로 제시할 수 있는 역량.

이번 프로젝트의 결과물

팀별 데이터 분석 발표

- 결과물: 팀별 데이터 분석
- 발표목표: 문제정의부터 인사이트 도출과 제안까지의 분석 과정을 전달
- 구성: 발표 구성 템플릿 8단계에 따라 정리

결과물이 증명하는 역량

역량 :

- 데이터를 조회, 가공하는 능력 (SQL)
- 데이터를 시각화하여 설명할 수 있는 스킬 (Tableau)
- 문제를 정의하고 가설을 세워 근거를 만드는 논리적 사고
- 분석 결과를 의사결정으로 연결하는 능력
- 함께 일하는 사람과의 커뮤니케이션

발표 구성 템플릿

섹션	답을 내용	예시 (olist)
1. 문제정의	왜 이 분석을 하는지, 누구의 의사결정을 돕는지	판매자 지역에 따라 배송 소요일수가 다르게 나타나는 이유를 파악한다
2. 데이터 소개	사용한 데이터의 특징과 한계	olist, 브라질 이커머스 실거래 데이터 (고객·주문·상품·판매자·결제·배송·리뷰)
3. 가설 소개	문제정의를 검증 가능한 질문으로 쪼갠 것 (3개 이상)	판매자와 고객 간 거리가 멀수록 배송이 오래 걸릴 것이다 등
4. 분석 과정	가설 검증을 위해 SQL·Tableau로 수행한 작업 흐름	지역별 평균 배송일수 집계 → 거리·물류거점과의 관계 확인 → 시각화
5. 핵심 인사이트	가설 검증 결과, 새롭게 알게 된 사실	특정 지역은 평균 배송일수가 0일 더 길었다
6. 액션 제안	인사이트를 바탕으로 한 제안	배송이 느린 지역에 물류 거점 추가를 검토한다
7. 학습 내용 및 다음 단계	진행 중 어려웠던 점, 배운 점, 확장 방향	팀별 작성
8. 부록 (선택)	상세 코드, 추가 시각화, 상세 분석 과정	팀별 작성

발표 구성 템플릿

1. 문제정의

- 이 프로젝트를 왜 시작했는지, 그리고 이 분석이 누구에게 어떤 의사결정을 돕기 위한 것인지를 설명합니다.

2. 데이터 소개

- 분석에 사용한 데이터가 어떤 데이터인지 간단히 설명합니다.
 - 데이터의 주요 특징
 - 분석 결과 해석에 영향을 줄 수 있는 한계

발표 구성 템플릿

3. 가설 소개

- 문제정의를 어떤 관점에서 검증하고자 했는지 설명합니다.
 - 3~4개 정도의 핵심 가설만 제시
 - “무엇을 확인하고 싶었는가”에 집중

4. 분석 과정 (간략)

- 어떤 흐름으로 분석을 진행했는지 큰 그림만 전달합니다.
 - 분석의 주요단계
 - 핵심적으로 수행한 분석 방법
 - 상세한 코드나 전처리 과정은 부록으로 분리
 - 분석 과정 설명이 아니라 ‘분석 흐름’ 요약

발표 구성 템플릿

5. 핵심 인사이트

- 분석을 통해서 무엇을 알게 되었는지를 명확히 전달합니다.
 - 가장 중요한 인사이트 1~3개
 - 데이터 분석을 통해 새롭게 발견한 점.
 - 분석 결과를 사람의 언어로 해석하기

발표 구성 템플릿

6. 액션 제안

- 인사이트를 바탕으로 실제로 무엇을 하면 좋을지를 제안합니다.
 - 실행 가능한 개선방향
 - 우선적으로 고려할 액션

7. 학습 내용 및 다음 단계

- 프로젝트를 통해서 무엇을 배웠고 앞으로 어떻게 확장할지 정리합니다.
 - 프로젝트 진행 중 어려웠던 점
 - 그 과정에서 배운 점
 - 이후 프로젝트의 발전 방향

발표 구성 템플릿

8. 부록 (필수 x)

- 전처리 및 분석 코드
- 추가 시각화 결과
- 상세 분석 과정

2

데이터 분석 프로젝트

데이터 분석 프로젝트 단계

1. 문제 정의
2. 가설 수립
3. 데이터 수집과 정리
4. 패턴 인식
5. 가설 검증
6. 결론과 의사 결정

1. 문제정의

- 문제정의란?
 - 현장이나 비즈니스의 모호한 요구를 무엇을 해결할지 명확한 질문으로 바꾸는 것

*“대략적인 문제에 대한 정확한 답을 내기보다,
올바른 문제에 대해 대략적인 답을 내는 것이 바람직하다.”*

- 존 튜키-

1. 문제정의

- 문제정의를 만드는 순서
 - 데이터를 훑어보며 궁금한 점을 자유롭게 적는다.
 - 그중 데이터로 확인 가능하고 팀이 관심이 있는 것을 고른다.
 - 문장으로 다듬는다.

1. 문제정의

- 문제 후보 찾는 방법
 - 비교할 수 있는 두 대상을 나눠본다 (이전 vs 이후, A그룹 vs B그룹, 이 지역 vs 저 지역)
 - 그 사이에서 눈에 띄는 차이나 패턴을 찾는다 (유독 크거나 작은 값 등)
 - 차이를 찾았다면 거기서 멈추지 말고 "왜 이런 차이가 날까?"를 반드시 붙여본다 — 이 한 걸음이 얇은 문제정의를 본질적인 문제정의로 바꾼다

1. 문제정의

- 한 번 작성하고 끝나는 것이 아니라, 해결 과정에서 끊임없이 재검토 필요
- 가지고 있는(구할 수 있는) 데이터에 따라서 문제 정의가 필요함.
- 비즈니스적인 결정을 할때 도움을 주는 데이터 분석인지 고민

1. 문제정의

- 좋은 문제정의의 기준
 - 문장이 명확하다 — 읽으면 바로 이해된다
 - 막연한 표현이 없다 — "좋아졌으면 한다" 같은 추상적인 문장은 피한다
 - 범위가 구체적이다 — 언제, 무엇을 대상으로 하는지 정해져 있다
 - 단순 비교·집계로 끝나지 않고 "왜"를 묻는다 — 그래야 답을 찾기 위한 가설을 여러 개 세울 수 있다

2. 가설 수립

- 가설이란?
 - 가설은 막연한 추측 x
 - 문제정의라는 하나의 큰 질문을, 데이터로 확인 가능한 여러 개의 작은 질문으로 나누는 것

2. 가설 수립

- 가설을 세우는 이유
 - 문제정의만 갖고 바로 데이터를 보면 확인해야 할 범위가 너무 넓다
 - 가설은 그 범위를 좁혀주는 역할을 한다 — "이런 조건이면 이런 결과가 나올 것이다"라고 미리 방향을 정해두는 것
 - 방향이 정해져 있어야, 데이터에서 무엇을 확인하면 되는지가 명확해진다
 - 가설 없이 보면 데이터를 무작정 뒤지게 되고, 가설이 있으면 확인할 대상이 분명해진다

2. 가설 수립

- 가설 세우는 순서
 - 문제정의 한 문장을 다시 읽는다
 - "왜 그럴까?"를 스스로 3번 물어본다
 - 떠오르는 이유를 가설로 적는다 (최소 3개)
 - 그 가설을 지금 가진 데이터로 확인할 수 있는지 체크한다

2. 가설 수립

좋은 가설의 조건

- 문제 정의와 연결 되는가?
- 데이터로 측정 가능한 지표 (수치, 비율, 순위)로 표현되는가?
- “~할 것이다”의 형태로 방향성이 명확한가

2. 가설 수립

나쁜 예	왜 나쁜가	좋은 예
지하철 이용객이 많을 것 같다	기준이 없어 검증 불가	오피스 밀집 지역이 베드타운 지역보다 평일 출근시간대(7~9시) 승차 비율이 높을 것이다
아파트 가격이 비쌀 것 같다	무엇 대비 비싼지 불명확	층수가 높을수록 동일 면적 대비 거래가격이 비쌀 것이다
상권이 활발할 것 같다	활발함의 기준이 없음	유동인구 대비 매출 효율은 강남구보다 중구가 높을 것이다

3. 데이터 수집 및 정리

- 데이터 추출, 정합성 검사, 전처리에 해당하는 과정
- 분석에 적합한 형태로 데이터 바꾸기
- 데이터 전처리 과정(결측치 처리, 데이터 정제 등)

데이터 전처리의 단계?

1. 데이터 이해 및 탐색
2. 데이터 정제
3. 데이터 형식의 통일
4. 데이터 변환
5. 데이터 통합
6. 피처 엔지니어링
7. 데이터 품질 검증

데이터 이해 및 탐색

1. 데이터의 구조, 타입, 첫 번째 몇 줄의 데이터를 살펴보며
데이터에 대한 초기 이해
2. 기본 통계량(평균, 중앙값, 표준편차 등)을 확인하여
데이터의 기본적인 특성 파악

데이터 정제

1. 결측치 처리 : 결측치가 있다면 적절하게 처리
 - ex) 평균값이나 중앙값 대체 또는 행이나 열 제거
2. 이상치 탐지 및 처리
 - 박스 플롯 등을 사용하여 이상치 탐지, 제거하거나 대체하기

데이터 형식의 통일

1. 날짜, 시간 등의 데이터 타입을 적절한 형식으로 변환
2. 문자열 데이터에서 대소문자를 통일하거나, 공백 제거

데이터 변환

1. 범주형 데이터 처리 :

원-핫 인코딩 등을 사용하여 범주형 데이터를 수치형으로 변환
(예, 아니오를 0 또는 1로 표현)

2. 정규화 및 표준화 : 숫자 데이터의 스케일을 조정

데이터 통합

1. 여러 테이블에서 수집된 데이터를 하나의 세트로 통합
2. 데이터 통합 시 키(key)가 되는 열을 잘 확인하고
중복 또는 불일치하는 데이터를 처리합니다.

피처 엔지니어링

1. 데이터에서 새로운 피처(column)을 생성하거나, 기존 피처를 변형하여 분석에 더 유용하게 만듦
2. 불필요하거나 중복적인 피처는 제거

데이터 품질 검증

1. 전처리한 데이터의 품질을 검증
Ex) 결측치나 이상치 처리
2. 데이터의 일관성과 정확성을 다시 한 번 확인

데이터 검토, 정합성 검사, 전처리

*“ 데이터 과학의 80%는 데이터 클리닝에 소비되고,
나머지 20%는 데이터 클리닝 하는 시간을 불평하는데 쓰인다 ”*

- 안소니 골드블럼 (전 캐글 CEO) -

4. 패턴 인식

- EDA를 통해서 데이터 내의 패턴, 추세, 상관관계 등을 탐색
- 데이터 시각화, 통계적 분석을 통해 중요한 인사이트를 발견

EDA !

Exploratory Data Analysis, 탐색적 데이터 분석.

주어진 데이터를 "탐색"하고 "이해"하는 과정!

= 데이터에 대한 일종의 "견적"을 내는 일

EDA !

“탐색적 데이터 분석(EDA)는
우리가 존재한다고 믿는 것들은 물론이고
존재하지 않는다고 믿는 것들을 발견하려는
태도, 유연성, 그리고 자발성이다”

- 존 튜키 (도서 Doing Data Science 중) -


EDA !

1. 데이터의 각 column들과 row의 의미 이해
2. 결측치 처리 및 데이터 클렌징
3. 시각화

EDA !



어떤 결과값을 낼 지 '가설'을 가지고
기본적인 표나 그래프를 간단히 그려보며
'사전 검증'을 하는 과정



데이터 분석을 통한 결과값
(표/그래프 등)을 출력

EDA 데이터 분석이란?

로우데이터(raw data) 이해 및 파악



어떤 결과를 만들어낼 지 데이터를 여러 측면으로 쪼개고, 출력



인사이트를 얻어내는 것

EDA 데이터 분석에서 주의해야할 점?

무의식적 판단 / 인지적 편향 X



정보(데이터)

5. 가설 검증

- 초기에 설정한 가설을 데이터를 통해 검증
- 필요한 경우 모델링을 통해 가설을 검증

6. 결론과 의사결정

- 분석 결과를 바탕으로 결론을 도출
 - 분석 결과 : 데이터 분석 과정에서 나온 직접적인 출력 (ex. 통계적 수치, 차트 등)
 - 결론 : 분석 결과를 해석하여 그 의미를 도출
 - 분석 결과가 비즈니스 문제, 기회, 전략 등과 어떻게 연결되는지를 설명
 - 결과를 기반으로 실질적인 비즈니스 의사 결정
- (선택사항) 발견된 문제를 해결할 수 있는 서비스를 제안해도 좋습니다



3

데이터 소개

데이터 베이스 세팅

DBeaver 연결 방법

- 상단 메뉴 → **Database** → **New Database Connection**

- **MySQL** 선택 → Next

- 입력:

Server Host: db.ttaya.dev

Port: 13306

Database: 아무것도 적지 않고 비워두기

Username: student_ro

Password: class_101

1. adventure_works

도메인: 글로벌 소비자 판매·유통

여러 연도에 걸친 판매 이력(Sales), 고객(Customers), 제품(Products), 제품 분류(Category/Subcategory), 지역(Territories), 달력(Calendar), 반품>Returns) 데이터를 포함한 데이터베이스입니다.

제조 공정이나 생산 데이터보다는, 제품 판매와 고객 구매, 지역별 매출 흐름을 분석하기 위한 판매 중심의 데이터 구조로 구성되어 있습니다.

<https://www.kaggle.com/datasets/ukveteran/adventure-works?resource=download>

2. bike_stores

도메인: 오프라인 소매 유통(자전거 리테일)

여러 매장을 운영하는 자전거 소매 체인을 가정한 데이터베이스로, 상품(자전거), 브랜드, 카테고리, 매장, 재고, 고객, 주문, 직원 정보를 포함하고 있습니다.

오프라인 매장 단위의 판매와 재고 흐름을 중심으로 한 전형적인 리테일 비즈니스 구조를 담고 있습니다.

<https://www.kaggle.com/dillonmyrick/bike-store-sample-database>

3. sakila

도메인: 오프라인 대여 서비스(영화 대여점)

영화 대여점을 가정한 데이터베이스로, 영화, 배우, 카테고리, 고객, 대여, 결제, 매장 정보를 포함하고 있습니다.

디지털 스트리밍이 아닌 오프라인 매장 중심의 대여·반납·결제 흐름을 데이터로 표현한 서비스형 비즈니스 구조입니다.

<https://www.kaggle.com/datasets/atanaskanev/sqlite-sakila-sample-database>

4. olist

도메인: 이커머스(온라인 마켓플레이스)

브라질 온라인 마켓플레이스의 실제 공개 데이터를 기반으로 한 데이터베이스로, 고객, 주문, 상품, 판매자, 결제, 배송, 리뷰 정보를 포함하고 있습니다.

온라인 쇼핑 전 과정(구매-결제-배송-후기)이 데이터로 연결된 전형적인 이커머스 서비스 구조를 표현합니다.

<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

5. chinook

도메인: 디지털 콘텐츠 유통(음원 스토어)

온라인 음원 스토어를 가정한 데이터베이스로, 아티스트, 앨범, 트랙, 장르, 재생목록과 고객, 결제(Invoice) 정보를 포함하고 있습니다.

물리적 재고나 배송 없이 디지털 콘텐츠 판매와 고객 구매 이력 중심으로 구성된 서비스형 플랫폼 비즈니스 구조입니다.

<https://www.kaggle.com/datasets/ranasabrii/chinook>

6. 서울 공공자전거 대여 이력

seoul_bike_rental

서울특별시 공공자전거 대여이력 정보입니다.

자전거 이동경로에 대한 데이터 분석이 가능하도록 년도별, 대여소별, 자전거별 대여이력 원천 데이터를 제공합니다.

<https://data.seoul.go.kr/dataList/OA-15182/F/1/datasetView.do>

7. 서울 지하철 승하차

seoul_subway

출처 서울열린데이터광장 (교통카드 이용정보)

기간 2015년 1월 ~ 2026년 7월 (139개월)

규모 약 406만 행 — 현재 가장 큰 DB

서울특별시 지하철 승하차 이력 정보입니다.

2015년 1월부터 2026년 7월까지의 서울 지하철 승하차 이용정보 데이터를 담고 있습니다.

역 정보·시간대별 승하차·유무임 승하차 등 3개 테이블로 구성됩니다.

자료를 바탕으로 코로나 전후 이용 패턴 변화, 출퇴근 시간대 베드타운과 오피스 지역 비교, 무임 승차 비율을 통한 인구 구조 분석 등에 유용합니다.

<http://data.seoul.go.kr/dataList/7/literacyView.do>

8. 서울 아파트 실거래

seoul_apt

출처 국토교통부 실거래가 공개시스템

기간 2021년 1월 ~ 2025년 12월

규모 약 154만 행

서울특별시 서울 아파트 실거래 이력 정보입니다.

자치구·법정동, 아파트 단지 마스터, 매매/전월세 실거래 4개 테이블로 구성됩니다. 집계 통계가 아닌 개별 거래 건 단위이므로 전세가율, 갱신요구권 사용 영향, 층·면적별 가격 분포 등 정밀한 통계 분석이 가능합니다.

<http://rt.molit.go.kr/>

9. 서울 상권분석

seoul_trade_area

출처 서울열린데이터광장 (골목상권분석정보)

기간 2021년 1분기 ~ 2026년 1분기 (분기 단위)

규모 약 210만 행

상권과 서비스 업종 차원에 점포 수, 추정 매출, 유동인구, 직장인구 등 10개 팩트 테이블이 연결됩니다. 유동인구 대비 매출 효율, 업종별 폐업률, 배후지 아파트 가격과 소비 패턴의 연관성을 분석하기 좋습니다. 2024년 기준 중구 상권이 강남구 대비 상권 수 대비 높은 매출 효율을 보이는 식의 인사이트 도출이 가능합니다.

<http://data.seoul.go.kr/dataList/3/literacyView.do>

10. 항공통계

aviation_stats

도메인: 항공 운송 (공항·항공사·노선)

출처: 국토교통부 항공통계시스템 (data.go.kr)

기간: 2017년 1월 ~ 2026년 7월 (월별)

규모: 약 5.4만 행 (마스터 3종 + 월별통계 3종 + 월별소계 3종, 총 9개 테이블)

전 세계 공항 마스터(5,498개, IATA/ICAO 코드 포함)와 국내 15개 공항·항공사 225개사·노선 991개의 여객·운항·화물 월별 실적을 담고 있습니다. 다른 데이터셋과 달리 **마스터 테이블 + 월별통계 테이블 + 월별소계 테이블이 분리된 구조**라 JOIN 실습에 특히 적합하고, 코로나 전후 항공 수요 변화, 국내선·국제선 노선별 회복 추이 등을 분석하기 좋습니다.

<https://www.airportal.go.kr/>

4

발표 구성 템플릿

5

팀 빌딩

팀 빌딩

의사결정자

필수!

팀장
의사결정, 팀 출석확인

기록 담당자

서기
Team Notion 관리

연결 담당자

필수!

전체적인 흐름을 이해하고
전달하는사람
발표자



프로젝트 매니저

필수!


의사결정자 대행
일정관리, 타임키퍼

기술 담당자

기술 담당
교부재 관리, 툴 관리

Daily Scrum ?

- 날마다 하는 짧은 회의
- 회의 목적: 매일 현재 상태를 업데이트하고 조율하는 것



Daily Scrum ?

Daily Scrum 규칙

- 지난 Daily Scrum 부터 지금까지 내가 완수한 것 공유
- 다음 Daily Scrum 까지 내가 하기로 한 것 공유
- 현재 장애가 되고 있는 것(곤란하고 어려운 것) 공유
 - Ex) 컨디션 저조, 면접을 보러 가야한다 등