

데이터 분석 프로젝트

8/20 ~ 8/25

방선기

1

프로젝트 일정

프로젝트 일정

8/20 (목) : 데이터셋 선정 / 문제 후보 발굴 / 문제정의 확정 / 데이터 전처리

8/21 (금) : 데이터 전처리 / 데이터 분석 (EDA / 시각화 / 인사이트 도출)

8/24 (월) : 데이터 분석 & 발표자료 준비

8/25 (화) : 발표자료 준비 & 팀별 발표

3

데이터 소개

데이터 베이스 세팅

DBeaver 연결 방법

- 상단 메뉴 → **Database** → **New Database Connection**
- **MySQL** 선택 → Next
- 입력:

Server Host: db.ttaya.dev

Port: 13306

Database: 아무것도 적지 않고 비워두기

Username: student_ro

Password: class_101

1. adventure_works

도메인: 글로벌 소비자 판매·유통

여러 연도에 걸친 판매 이력(Sales), 고객(Customers), 제품(Products), 제품 분류(Category/Subcategory), 지역(Territories), 달력(Calendar), 반품>Returns) 데이터를 포함한 데이터 베이스입니다.

제조 공정이나 생산 데이터보다는, 제품 판매와 고객 구매, 지역별 매출 흐름을 분석하기 위한 판매 중심의 데이터 구조로 구성되어 있습니다.

<https://www.kaggle.com/datasets/ukveteran/adventure-works?resource=download>

2. bike_stores

도메인: 오프라인 소매 유통(자전거 리테일)

여러 매장을 운영하는 자전거 소매 체인을 가정한 데이터베이스로, 상품(자전거), 브랜드, 카테고리, 매장, 재고, 고객, 주문, 직원 정보를 포함하고 있습니다.

오프라인 매장 단위의 판매와 재고 흐름을 중심으로 한 전형적인 리테일 비즈니스 구조를 담고 있습니다.

<https://www.kaggle.com/dillonmyrick/bike-store-sample-database>

3. sakila

도메인: 오프라인 대여 서비스(영화 대여점)

영화 대여점을 가정한 데이터베이스로, 영화, 배우, 카테고리, 고객, 대여, 결제, 매장 정보를 포함하고 있습니다.

디지털 스트리밍이 아닌 오프라인 매장 중심의 대여·반납·결제 흐름을 데이터로 표현한 서비스형 비즈니스 구조입니다.

<https://www.kaggle.com/datasets/atanaskanev/sqlite-sakila-sample-database>

4. olist

도메인: 이커머스(온라인 마켓플레이스)

브라질 온라인 마켓플레이스의 실제 공개 데이터를 기반으로 한 데이터베이스로, 고객, 주문, 상품, 판매자, 결제, 배송, 리뷰 정보를 포함하고 있습니다.

온라인 쇼핑 전 과정(구매-결제-배송-후기)이 데이터로 연결된 전형적인 이커머스 서비스 구조를 표현합니다.

<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

5. chinook

도메인: 디지털 콘텐츠 유통(음원 스토어)

온라인 음원 스토어를 가정한 데이터베이스로, 아티스트, 앨범, 트랙, 장르, 재생목록과 고객, 결제 (Invoice) 정보를 포함하고 있습니다.

물리적 재고나 배송 없이 디지털 콘텐츠 판매와 고객 구매 이력 중심으로 구성된 서비스형 플랫폼 비즈니스 구조입니다.

<https://www.kaggle.com/datasets/ranasabrii/chinook>

6. 서울 공공자전거 대여 이력

seoul_bike_rental

서울특별시 공공자전거 대여이력 정보입니다.

자전거 이동경로에 대한 데이터 분석이 가능하도록 년도별, 대여소별, 자전거별 대여이력 원천 데이터를 제공합니다.

<https://data.seoul.go.kr/dataList/OA-15182/F/1/datasetView.do>

7. 서울 지하철 승하차

seoul_subway

출처 서울열린데이터광장 (교통카드 이용정보)

기간 2015년 1월 ~ 2026년 7월 (139개월)

규모 약 406만 행 — 현재 가장 큰 DB

서울특별시 지하철 승하차 이력 정보입니다.

2015년 1월부터 2026년 7월까지의 서울 지하철 승하차 이용정보 데이터를 담고 있습니다.

역 정보·시간대별 승하차·유무임 승하차 등 3개 테이블로 구성됩니다.

자료를 바탕으로 코로나 전후 이용 패턴 변화, 출퇴근 시간대 베드타운과 오피스 지역 비교, 무임 승차 비율을 통한 인구 구조 분석 등에 유용합니다.

<http://data.seoul.go.kr/dataList/7/literacyView.do>

8. 서울 아파트 실거래

seoul_apt

출처 국토교통부 실거래가 공개시스템

기간 2021년 1월 ~ 2025년 12월

규모 약 154만 행

서울특별시 서울 아파트 실거래 이력 정보입니다.

자치구·법정동, 아파트 단지 마스터, 매매/전월세 실거래 4개 테이블로 구성됩니다. 집계 통계가 아닌 개별 거래 건 단위이므로 전세가율, 갱신요구권 사용 영향, 층·면적별 가격 분포 등 정밀한 통계 분석이 가능합니다.

<http://rt.molit.go.kr/>

9. 서울 상권분석

seoul_trade_area

출처 서울열린데이터광장 (골목상권분석정보)

기간 2021년 1분기 ~ 2026년 1분기 (분기 단위)

규모 약 210만 행

상권과 서비스 업종 차원에 점포 수, 추정 매출, 유동인구, 직장인구 등 10개 팩트 테이블이 연결됩니다. 유동인구 대비 매출 효율, 업종별 폐업률, 배후지 아파트 가격과 소비 패턴의 연관성을 분석하기 좋습니다. 2024년 기준 중구 상권이 강남구 대비 상권 수 대비 높은 매출 효율을 보이는 식의 인사이트 도출이 가능합니다.

<http://data.seoul.go.kr/dataList/3/literacyView.do>

10. 항공통계

aviation_stats

도메인: 항공 운송 (공항·항공사·노선)

출처: 국토교통부 항공통계시스템 (data.go.kr)

기간: 2017년 1월 ~ 2026년 7월 (월별)

규모: 약 5.4만 행 (마스터 3종 + 월별통계 3종 + 월별소계 3종, 총 9개 테이블)

전 세계 공항 마스터(5,498개, IATA/ICAO 코드 포함)와 국내 15개 공항·항공사 225개사·노선 991개의 여객·운항·화물 월별 실적을 담고 있습니다. 다른 데이터셋과 달리 **마스터 테이블 + 월별통계 테이블 + 월별소계 테이블이 분리된 구조**라 JOIN 실습에 특히 적합하고, 코로나 전후 항공 수요 변화, 국내선·국제선 노선별 회복 추이 등을 분석하기 좋습니다.

<https://www.airportal.go.kr/>